

修士論文

令和 X 年度 (20YY 年度)

日本語タイトル

English Title

学籍番号

氏名 山田 太郎

指導教員 教授 関山 浩介

目次

第1章 英訳	1
1.1 Introduction	1
1.2 Related Work	2
1.3 Human–Robot Interaction with Correction and Suggestion (HRI-CAS) . .	4
1.3.1 Implementation Platform and System	5
1.3.2 MR System Implementation	6
1.4 Module of Human–Robot Interaction with Correction and Suggestion (HRI-CAS)	7
1.4.1 Target Bottle Inference (TBI) Module	7
1.4.2 Base Relocation based on Inverse Reachability Map (BRI)	10
1.4.3 Human-Intent Adaptive Grasp Manipulation (HIGM)	14
1.4.4 Significance of Module Integration	17
1.5 Experiment on BRI	18
1.5.1 Experimental Setup	18
1.5.2 Experimental Results	19
1.6 Experiment on HIGM	19
1.6.1 Experimental Setup	19
1.6.2 Experimental Results	21
1.7 Conclusions	21
第2章 和訳	1
2.1 序論 (Introduction)	1
2.2 関連研究 (Related Work)	2
2.3 Human–Robot Interaction with Correction and Suggestion (HRI-CAS) . .	3
2.3.1 実装プラットフォームとシステム	4
2.3.2 MR システム実装	6
2.4 Module of Human–Robot Interaction with Correction and Suggestion (HRI-CAS)	6
2.4.1 操作対象推定モジュール (Target Bottle Inference, TBI)	6
2.4.2 逆到達可能マップに基づくベース移動 (Base Relocation based on Inverse Reachability Map, BRI)	9
2.4.3 人間意図適応型把持操作補正 (Human-Intent Adaptive Grasp Manipulation, HIGM)	13
2.4.4 モジュール統合の意義	16
2.5 BRI の実験	17
2.5.1 実験設定	17

目 次

2.5.2	実験結果	18
2.6	HGIM の実験	18
2.6.1	実験設定	18
2.6.2	実験結果	19
2.7	結論	19
参考文献		20

图 目 次

1.1	Figure1	5
1.2	Figure2	5
1.3	Figure3	7
1.4	Figure4	9
1.5	Figure5	9
1.6	RM/IRM	10
1.7	Figure7	11
1.8	Figure4	12
1.9	Figure4	13
1.10	Figure10	15
1.11	Figure11	16
1.12	Figure12	17
1.13	Overview of BRI pipeline	18
1.14	Sequential pick-and-place before/after	20
1.15	Sequential pick-and-place	20
1.16	Sequential pick-and-place	21
2.1	Figure1	4
2.2	Figure2	5
2.3	Figure3	6
2.4	Figure4	8
2.5	Figure4	8
2.6	RM/IRM	9
2.7	Figure7	10
2.8	Figure4	11
2.9	Figure4	12
2.10	Figure10	14
2.11	Figure10	15
2.12	Figure10	16
2.13	Figure4	17
2.14	Figure4	17
2.15	Figure4	18
2.16	Figure4	19

第1章 英訳

1.1 Introduction

In recent years, Human-Robot Collaboration (HRC) has attracted significant attention as an important research domain in which humans and robots cooperate to accomplish tasks in diverse working environments[1][2]. The aim is not only for robots to interpret human intentions more accurately but also to enable smooth and intuitive communication. When working in shared spaces, the synergy between humans and robots can be expected to improve both efficiency and safety.

One of the major challenges in HRC lies in the discrepancy between human intention and robotic perception. Such mismatches often cause reductions in task efficiency and increase the difficulty of operation. In particular, operational mismatches stemming from the differences in embodiment between humans and robots represent a fundamental bottleneck in collaborative work. To address this issue, approaches that leverage Mixed Reality (MR) to intuitively map human operations onto robots have been actively studied. MR enables users to recognize robotic motion as an extension of their own body, thereby fostering more natural and seamless collaboration [3][4][5][6][7].

Frameworks for intuitive operation support in HRC have also been reported not only with MR but also through Augmented Reality (AR) and Virtual Reality (VR). For example, VR-based methods have been proposed for imitation learning and motion data collection, allowing robots to efficiently acquire manipulation skills [8] [9][10]. Meanwhile, AR-based approaches have sought to present robot states and task procedures to the user, thereby enhancing task comprehension [11] [12][13]. Although these works have shown the effectiveness of bridging recognition gaps between humans and robots, limitations remain in terms of immersion and interaction with the real-world environment. In this context, MR is particularly promising because it allows for the seamless integration of real-world environments with virtual information, thus enabling more intuitive and adaptive HRC.

A representative prior study is the work by Esaki et al., entitled Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO)[14]. IRT-MRO demonstrated the effectiveness of HRC using MR by enabling humans to intuitively manipulate virtual objects in MR space, with the robot recognizing and executing corresponding positional and postural changes. However, several challenges remain unresolved, including the integration of environmental perception, the assurance of stable robot posture, and the autonomy of base relocation strategies.

To address these challenges, this study proposes Human-Robot Interaction with Correction and Suggestion (HRI-CAS). The system integrates three key components: Target

Bottle Inference (TBI), which estimates the target object based on user operation features; Base Relocation based on the Inverse Reachability Map (BRI), which provides a base movement strategy utilizing the IRM; and Human-Intent Adaptive Grasp Manipulation (HIGM), a grasping framework that compensates for the embodiment gap between humans and robots. By combining these components, HRI-CAS enables stable collaborative work independent of the user's skill level and aims to realize bidirectional and interactive HRC through MR space.

Contributions

The main contributions of this study can be summarized as follows:

- **Proposal of the Target Bottle Inference (TBI) module** By integrating user operation features such as hand proximity, contact, gaze, and arm motion, and weighting them according to reachability, the TBI module infers the intended object of manipulation. This approach suppresses unnecessary information presentation while supporting intuitive target selection.
- **Design and realization of based on the Inverse Reachability Map (BRI)** By utilizing the Inverse Reachability Map[17], the system computes feasible base positions for grasping and visualizes candidate paths in MR space. Users can edit these paths interactively, thereby achieving a balance between autonomy and interactivity in determining whether base relocation is necessary.
- **Development of the Human-Intent Adaptive Grasp Manipulation (HIGM)** By combining pregrasp generation, nullspace optimization, and a finite state machine (FSM), the system continuously harmonizes user operations with robot manipulability. This enables seamless collaborative manipulation based on mutual correction and suggestion.

Through these contributions, the proposed system allows robots to respect user intentions while providing appropriate correction and suggestions, ensuring stable task execution regardless of user expertise. Furthermore, the proposed HRI-CAS framework demonstrates applicability to real-world tasks where humans and robots closely collaborate, such as in manufacturing sites, remote maintenance, and medical support. This work is thus expected to contribute to the further development of HRC research.

1.2 Related Work

Robots are expected to support human life and activities in a wide range of fields such as medicine, manufacturing, space exploration, and agriculture. However, many challenges remain for humans and robots to work collaboratively in the same space. One of these is the lack of mutual understanding of intentions and actions. Humans often find it difficult to accurately predict the capabilities and behaviors of robots, while robots

cannot fully interpret humans' high-level goals. As a result, "gaps of execution" and "gaps of evaluation" arise, hindering smooth collaboration. Conventional interfaces have mainly relied on joysticks or keyboards, but visualization on 2D displays provides insufficient depth information, limiting the operator's spatial awareness and sense of immersion.

To address these challenges, research on Human-Robot Collaboration (HRC) using Mixed Reality (MR) has made significant progress in recent years. By overlaying information about robot states and environmental conditions in MR space, users can perform more intuitive operations, and improvements in efficiency for teleoperation and collaborative tasks can be expected [3] [4].

In addition, many studies have explored applications of AR and VR. In VR, methods have been proposed to support skill acquisition by robots through imitation learning and motion data collection [8] [9], while in AR, attempts have been made to assist workers' understanding by presenting task procedures and robot states [11] [12]. Nevertheless, these approaches still face limitations in interaction with the real environment and in providing a sense of immersion.

In this context, MR, which can integrate the real world with virtual information, is receiving particular attention as a promising foundation technology for HRC. Previous MR-based HRC research can largely be classified into two directions.

First, research focusing on **visualization of robot states**. This direction projects sensor data and robot internal states into MR space, thereby supporting users' situational awareness and decision-making [15]. While this approach contributes to enhancing environmental understanding and reducing cognitive load, direct intervention in robot motion planning and control remains limited.

Second, research focusing on **intuitive mapping of user operations**. By converting hand tracking and gesture inputs into robot motions, attempts have been made to enhance operability and immersion [3][4][5][6][7]. Although this approach allows the operator's intentions to be reflected more naturally, the stability of the operation and the guarantee of robot manipulability are often insufficient.

In this category, the work of Esaki et al. is representative. They proposed the **Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO)** [14]. In IRT-MRO, objects are placed in MR space, and users directly manipulate their positions and orientations. The manipulated results are transferred to the robot side, enabling the robot to execute the same operations in the physical world. This demonstrated the effectiveness of MR in improving the intuitiveness of robot teleoperation.

However, IRT-MRO also leaves several issues unresolved. First, because the system simply transfers the object manipulation performed by the user in MR space, it does not take into account whether the robot can actually reach the target object or grasp it stably. Second, the posture of the robot arm is not always guaranteed to remain safe,

and problems such as singularity or joint limit violations can occur. Third, when an object is located outside the reachable area of the robot, the system does not provide an appropriate relocation strategy for the robot base, leaving the operation incomplete.

In summary, while existing studies have clearly demonstrated the effectiveness of MR for HRC, they have not yet resolved several key challenges, such as the lack of integration of environmental information, the absence of stable operation considering redundant degrees of freedom, and the insufficient autonomy of base relocation strategies. Moreover, inherent limitations of MR technology itself remain, including the lack of haptics and constraints on real-time processing performance [16]. Against this background, this study proposes Human–Robot Interaction with Correction and Suggestion (HRI-CAS).

1.3 Human–Robot Interaction with Correction and Suggestion (HRI-CAS)

Human–Robot Interaction with Correction and Suggestion (HRI-CAS) addresses several limitations observed in conventional MR-based HRC systems, including insufficient utilization of environmental information, lack of stable posture guarantees, and inadequate autonomy in base relocation strategies.

This system is built upon the foundation of *Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO)* and improves upon the issues that remained in IRT-MRO. Whereas IRT-MRO employed a Unity-based holographic application on the HoloLens 2, the proposed system adopts a Unity-based passthrough application using the Meta Quest. Although both devices are capable of projecting real-world objects into MR space, they differ significantly in their display methods.

The HoloLens 2 adopts an optical see-through display, allowing the user to perceive both the real environment and virtual objects through a transparent screen. However, its limited field of view and restricted brightness have been widely noted. In contrast, as illustrated in Figure 2.16, the Meta Quest employs a passthrough display system, which projects images captured by external cameras onto the display, enabling a wide field of view and high-resolution rendering. This provides the user with a more natural and immersive MR experience, enhancing both environmental understanding and intuitive operation.



Fig.1.1: Figure1

1.3.1 Implementation Platform and System

In this study, the experimental platform adopted was the **KUKA YouBot**. The robot is a mobile manipulator equipped with an omnidirectional base, a 5-DOF manipulator, and a two-finger gripper. Within the proposed system, changes in the position and orientation of target objects detected in MR space, as well as user manipulations, are reflected directly in the robot's motion. This ensures smooth and seamless interaction between the human and the robot. Furthermore, the robot's behavior is immediately fed back into MR space, providing the operator with precise visual information in real time.

The graphical architecture of the system is illustrated in Figure?? and is composed of the following three modules:




Fig.1.2: Figure2

Target Bottle Inference (TBI) module: This module tracks the user ’ s gaze, head orientation, and hand motion within MR space, extracting geometric relationships with candidate bottles as features. These multimodal features are then processed through an integrated scoring framework to infer the bottle that the user intends to manipulate. By jointly evaluating diverse behavioral cues, the TBI module enables highly accurate and real-time target selection.

Base Relocation based on Inverse Reachability Map (BRI) module: When the target bottle lies outside the robot ’ s reachable workspace, this module becomes active. First, an Inverse Reachability Map (IRM) is generated based on the Reachability Map (RM)[17], and candidate base positions that make the target reachable are extracted. Next, an optimization problem is solved considering both the IRM score and the movement cost, yielding the optimal base configuration. Additionally, candidate paths are visualized within MR space, allowing users to refine or adjust the proposed routes interactively.

Human-Intent Adaptive Grasp Manipulation (HIGM) module: This module aims to reconcile the differences between the user ’ s intended manipulation and the robot ’ s physical and kinematic constraints. Specifically, it integrates reference postures obtained from hand-tracking information with robot-preferred pregrasp postures, and applies nullspace optimization to adjust joint configurations. As a result, the user can achieve stable grasping with natural operational feedback, without needing to be aware of the robot ’ s inherent kinematic constraints.

Through the integration of these modules, the proposed system achieves adaptive and intuitive motion planning that was not sufficiently addressed in IRT-MRO. The robot is now able to select actions according to the user ’ s intended target, while providing adaptive grasp correction without requiring the user to account for robot-specific constraints. This significantly reduces dependency on the user ’ s operational expertise and ensures smooth, stable operation even for novice users.

1.3.2 MR System Implementation

The MR system is implemented on **Unity** and **MRTK3 (Mixed Reality Toolkit)**, in compliance with the OpenXR standard. The user can manipulate MR objects directly through hand gestures, offering an intuitive and natural input interface. Moreover, by presenting the robot ’ s behavioral intentions through MR objects, the system improves the operator ’ s understanding of the robot ’ s decision-making process, thereby enhancing human-robot collaboration.

1.4 Module of Human–Robot Interaction with Correction and Suggestion (HRI-CAS)

1.4.1 Target Bottle Inference (TBI) Module

Definition of Features : The TBI module aims to estimate the user’s intended target object based on bodily movements. Figure1.3 illustrates the distribution of operational features in the information space.




Fig.1.3: Figure3

Let the position of a target object o_i be denoted as $\mathbf{p}_i(t)$, and the positions of the user’s eyes, head, and hand be $\mathbf{p}_{eye}(t)$, $\mathbf{p}_{head}(t)$, and $\mathbf{p}_{hand}(t)$, respectively. For each object, the normalized direction vectors from these body parts are defined as:

$$\mathbf{d}_i^{eye}(t) = \frac{\mathbf{p}_i(t) - \mathbf{p}_{eye}(t)}{\|\mathbf{p}_i(t) - \mathbf{p}_{eye}(t)\|}, \quad \mathbf{d}_i^{head}(t) = \frac{\mathbf{p}_i(t) - \mathbf{p}_{head}(t)}{\|\mathbf{p}_i(t) - \mathbf{p}_{head}(t)\|}, \quad \mathbf{d}_i^{hand}(t) = \frac{\mathbf{p}_i(t) - \mathbf{p}_{hand}(t)}{\|\mathbf{p}_i(t) - \mathbf{p}_{hand}(t)\|}. \quad (1.1)$$

These vectors geometrically define the directions in which the user is focusing attention or exerting effort. To incorporate dynamics of motion, normalized gaze, head orientation, and hand acceleration vectors are introduced as $\hat{\mathbf{v}}_{gaze}(t)$, $\hat{\mathbf{v}}_{head}(t)$, and $\hat{\mathbf{a}}_{hand}(t)$.

Cosine Similarity Scores : To evaluate whether the user’s body movements align with the direction of candidate objects, cosine similarity between these features and the direction vectors is computed:

$$s_{gaze}(i, t) = \max(0, \hat{\mathbf{v}}_{gaze}(t) \cdot \mathbf{d}_i^{eye}(t)), \quad (1.2)$$

$$s_{head}(i, t) = \max\left(0, \hat{\mathbf{v}}_{head}(t) \cdot \mathbf{d}_i^{head}(t)\right), \quad (1.3)$$

$$s_{accel}(i, t) = \max\left(0, \hat{\mathbf{a}}_{hand}(t) \cdot \mathbf{d}_i^{hand}(t)\right). \quad (1.4)$$

Here, s_{gaze} represents the degree to which the gaze is directed toward each object, s_{head} represents the degree to which the head orientation captures each object, and s_{accel} represents the degree to which the hand acceleration is aligned with the object’s direction.

In addition, physical graspability is considered by introducing: (i) a proximity score s_{prox} based on the Euclidean distance between the hand and the object, and (ii) a binary

contact variable $c_i(t)$:

$$s_{\text{prox}}(i, t) = \text{clip} \left(1 - \frac{\|\mathbf{p}_{\text{hand}}(t) - \mathbf{p}_i(t)\|}{R_{\text{max}}}, 0, 1 \right), \quad c_i(t) \in \{0, 1\}. \quad (1.5)$$

Thus, the module integrates both body movement and physical graspability. Here, $c_i(t)$ is treated as a mandatory flag for the final decision and is not included in the feature vector.

Score Integration : The feature vector is defined as

$$\mathbf{s}(i, t) = [s_{\text{prox}}, s_{\text{gaze}}, s_{\text{head}}, s_{\text{accel}}]^\top, \quad (1.6)$$

and the integrated score is calculated with different weightings depending on whether the target belongs to the reachable set $\mathcal{B}_{\text{in}}(t)$ or the unreachable set $\mathcal{B}_{\text{out}}(t)$:

$$S(i, t) = \begin{cases} \mathbf{w}_{\text{in}}^\top \mathbf{s}(i, t), & i \in \mathcal{B}_{\text{in}}(t), \\ \mathbf{w}_{\text{out}}^\top \mathbf{s}(i, t), & i \in \mathcal{B}_{\text{out}}(t). \end{cases} \quad (1.7)$$

Here, $\mathbf{w}_{\text{in}}$ and $\mathbf{w}_{\text{out}}$ are predefined weight vectors. For reachable objects, emphasis is placed on contact and proximity, ensuring robustness against noisy gaze fluctuations. For unreachable objects, emphasis is placed on gaze and hand motion, capturing the user's distal intention. This design enables flexible and error-tolerant inference depending on the situation.

Temporal Smoothing :

Since the score is expected to fluctuate rapidly due to momentary body movements, an exponential moving average is introduced to temporally smooth the score [18].

$$\bar{S}(i, t) = \alpha S(i, t) + (1 - \alpha) \bar{S}(i, t - 1), \quad \alpha \in (0, 1]. \quad (1.8)$$

Here, $\bar{S}(i, t)$ is the smoothed integrated score, and α is the smoothing coefficient. This prevents transient misdetections and allows stable inference of user intention.

Final Decision Rule : The final target is determined with priority given to contact. If there exists any candidate i such that $c_i(t) = 1$, that object is immediately selected:

$$i^*(t) \in \{i \in \mathcal{B} \mid c_i(t) = 1\}. \quad (1.9)$$

Otherwise, the target is selected as the one maximizing the smoothed score over the entire candidate set $\mathcal{B}$:

$$i^*(t) = \arg \max_{i \in \mathcal{B}} \bar{S}(i, t). \quad (1.10)$$

However, the selected object must satisfy threshold conditions:

$$\bar{S}(i^*(t), t) \geq \begin{cases} T_{\text{in}}, & i^*(t) \in \mathcal{B}_{\text{in}}(t), \\ T_{\text{out}}, & i^*(t) \in \mathcal{B}_{\text{out}}(t). \end{cases} \quad (1.11)$$

Here, T_{in} and T_{out} are thresholds for the reachable and unreachable sets, respectively. This two-step decision ensures that only targets with sufficiently strong intentional signals are confirmed.

Information Presentation Adjustment : When presenting inference results to the user, the TBI module adjusts the amount of information to prevent cognitive overload while supporting intuitive understanding.

First, as shown in Figure1.4, each candidate bottle is classified by the *Reachability Map (RM)* as “graspable” or “non-graspable.” Graspable objects are displayed with a base color[17], while non-graspable ones are rendered semi-transparent with reduced saturation, ensuring they do not unnecessarily attract the user ’ s attention.



Fig.1.4: Figure4

Furthermore, as illustrated in Figure1.5, once the target is inferred, all non-selected objects are displayed in semi-transparent form. At this stage, different highlighting schemes are used for graspable and non-graspable objects: graspable targets are emphasized with a color indicating manipulability, while non-graspable targets are highlighted with a different tone to indicate the need for base relocation.




Fig.1.5: Figure5

Through this two-step information adjustment, users can clearly distinguish between “objects that can currently be grasped” and “objects that require relocation.” By emphasizing the final inferred target, the system reduces selection errors and alleviates cognitive load, supporting intuitive decision-making.

Summary of TBI : In summary, the TBI module geometrically defines multiple bodily features such as gaze, head orientation, and hand motion, and integrates them through cosine similarity, proximity, and contact indicators to construct a robust scoring frame-

work. Temporal smoothing suppresses transient misdetections, ensuring stable real-time inference.

Furthermore, the inference results are visually presented in the MR space. Specifically, depending on the Reachability Map (RM) judgment of whether an object is graspable or not, graspable objects are displayed in their base color, whereas ungraspable ones are shown with reduced information through transparency or lowered saturation. In addition, the bottle inferred as the operation target is highlighted, and different highlight colors are used for graspable and ungraspable objects, thereby providing clear feedback to the user.

In this way, the TBI module integrates both “target inference” and “information presentation,” reducing the user’s cognitive load while preventing misselection of operation targets. As a result, it enables the accurate understanding of human intention, which serves as the oundation of the entire HRI-CAS framework.

1.4.2 Base Relocation based on Inverse Reachability Map (BRI)

When the target lies outside the robot’s reachable workspace, the robot base itself must be relocated. Naively exploring base candidates leads to prohibitive computational cost and makes it difficult to obtain configurations that respect human–robot collaboration. Therefore, as illustrated in Figure2.6, we introduce two concepts widely used in manipulator research—the *Reachability Map (RM)* and the *Inverse Reachability Map (IRM)*—to generate and evaluate candidate base poses [17].




Fig.1.6: RM/IRM

Basics of reachability and inverse reachability :

Given a robot base pose $\mathbf{b}$, the workspace that the end-effector (EE) can reach from $\mathbf{b}$ is defined as

$$RM(\mathbf{b}) = \{\mathbf{p} \in \mathbb{R}^3 \mid \exists \theta \text{ s.t. } FK(\theta, \mathbf{b}) = \mathbf{p}\}, \quad (1.12)$$

where $FK(\theta, \mathbf{b})$ denotes forward kinematics. In other words, if there exists a joint configuration θ , the point $\mathbf{p}$ is reachable from the fixed base $\mathbf{b}$. Thus, the RM specifies “how far the arm can reach from a fixed base pose.”

Conversely, for a given task point $\mathbf{p}_t$, the set of base poses that makes $\mathbf{p}_t$ reachable is

$$\mathcal{B}(\mathbf{p}_t) = \{\mathbf{b} \in \mathbb{R}^3 \mid \mathbf{p}_t \in RM(\mathbf{b})\}, \quad (1.13)$$

which we call the *Inverse Reachability Map (IRM)*. IRM is the inverse mapping that provides “the set of base poses from which the task point is reachable,” and is essential when base relocation is considered [17].

Beyond a binary reachable/unreachable decision, RM can evaluate stability/redundancy by counting the number of inverse kinematic (IK) solutions available at a point. In this work, the RM score for position $\mathbf{p}$ is defined by

$$S_{RM}(\mathbf{p}) = N_{IK}(\mathbf{p}). \quad (1.14)$$

A larger number of solutions implies greater redundancy and flexibility in motion, which typically increases grasp success rates.

Since IRM is the inverse of RM, each candidate base pose $\mathbf{b} \in \mathcal{B}(\mathbf{p}_t)$ for target $\mathbf{p}_t$ inherits the corresponding RM score:

$$S_{IRM}(\mathbf{b}; \mathbf{p}_t) = N_{IK}(\mathbf{p}_t \mid \mathbf{b}). \quad (1.15)$$

This allows us to assess candidate base configurations not only by “reachability,” but also by “how redundantly and stably” the target can be reached.

We now select the optimal base pose from the candidate set $\mathcal{B}(\mathbf{p}_t)$. As shown conceptually in Figure 1.7, we formulate two cases depending on the availability of environment/navigation information.




Fig.1.7: Figure7

Case: Known path

When a navigable path to the target is available, the base pose is selected by jointly considering the IRM score $S_{IRM}(\mathbf{b}; \mathbf{p}_t)$ and the movement cost $C(\mathbf{b})$:

$$\mathbf{b}^* = \arg \max_{\mathbf{b} \in \mathcal{B}(\mathbf{p}_t)} \left[S_{IRM}(\mathbf{b}; \mathbf{p}_t) - \lambda C(\mathbf{b}) \right]. \quad (1.16)$$

Here, $C(\mathbf{b})$ is defined as the navigation path length from the current base $\mathbf{b}_0$ to $\mathbf{b}$:

$$C(\mathbf{b}) = L(\Gamma(\mathbf{b})) = \int_0^1 \|\dot{\mathbf{x}}(s)\| ds \approx \sum_{k=1}^N \|\mathbf{x}_k - \mathbf{x}_{k-1}\|.$$

The resulting candidate base poses and the waypoint sequence are visualized in MR space, and the user can modify the route by directly manipulating the waypoints.




Fig.1.8: Figure4

User interaction (mathematical incorporation of path edits) Let the reference route edited by the user in MR space be $\bar{\Gamma}_u = \{\bar{\mathbf{x}}_k\}_{k=0}^N$, and let $\mathcal{K}_{\text{lock}}$ denote the set of pinned (fixed) indices. For each candidate base $\mathbf{b}$, the navigation module recomputes a path $\Gamma(\mathbf{b})$ by minimizing

$$C(\mathbf{b} \mid \bar{\Gamma}_u) = C(\mathbf{b}) + w_{\text{trk}}^{\text{nav}} \sum_{k \notin \mathcal{K}_{\text{lock}}} \|\mathbf{x}_k - \bar{\mathbf{x}}_k\|^2, \quad \text{s.t. } \Gamma(\mathbf{b}) \in \mathcal{F}_{\text{nav}}, \quad \mathbf{x}_k = \bar{\mathbf{x}}_k \quad (k \in \mathcal{K}_{\text{lock}}).$$

Then (2.16) is re-evaluated using the updated $\Gamma(\mathbf{b})$. The final base is chosen as

$$\mathbf{b}^* = \arg \max_{\mathbf{b} \in \mathcal{B}(\mathbf{p}_t) \cap \mathcal{F}_{\text{nav}}} \left[S_{\text{IRM}}(\mathbf{b}; \mathbf{p}_t) - \lambda C(\mathbf{b} \mid \bar{\Gamma}_u) - \xi \Delta \psi(\mathbf{b})^2 \right],$$

and the updated waypoint sequence $\Gamma(\mathbf{b}^*)$ is immediately re-rendered in MR space.

Case: Unknown path

When environment information is incomplete and path generation fails, we adopt the IRT-MRO [14] scheme: the user directly lays out a base route in MR space. On top of this, we introduce a local autonomous refinement using a cost map. As shown in Figure2.9, each waypoint is adjusted to a safe and feasible pose that accounts for obstacles and environmental changes. The refined route is immediately reflected in MR space so that the user can visually grasp the autonomous corrections made by the robot.

Cost map (OccupancyGrid $\rightarrow$ safety-aware grid) :

From an occupancy grid $G \in \{-1, 0, 100\}^{H \times W}$ (unknown = -1, free = 0, obstacle = 100), we construct a cost map $C \in \mathbb{R}^{H \times W}$. The per-cell base cost is

$$C_{ij} = \begin{cases} 100 & (G_{ij} = 100) \quad [\text{blocked}] \\ P_{\text{unk}} & (G_{ij} = -1) \quad [\text{mild penalty for unknown}] \\ 0 & (G_{ij} = 0), \end{cases}$$

followed by two dilations for safety margins. (i) Obstacle-proximity dilation by Manhattan distance $d_1 \leq d_{\text{avoid}}$ sets $C_{ij} \leftarrow P_{\text{pen}}$ (morphological expansion). (ii) Robot-radius expansion: with resolution h and safety radius r_{safe} , we set $r_c = \lceil r_{\text{safe}}/h \rceil$ and also assign $C_{ij} \leftarrow P_{\text{pen}}$ for all cells within Euclidean distance $\leq r_c$ of any obstacle. Here $P_{\text{pen}} \gg 1$ encodes “traversable but expensive,” thus naturally favoring paths that keep distance from obstacles (cf. Fig. 2.9).

Route proposal (MR reference $\rightarrow$ safe A* refinement) :

Let the user-provided MR reference route be $\bar{\Gamma} = \{\bar{\mathbf{x}}_k\}_{k=0}^N$, treated as a sequence of waypoints. For each segment ($\bar{\mathbf{x}}_{k-1} \rightarrow \bar{\mathbf{x}}_k$), we run A* on the safety-aware cost map to obtain a safe path Π_k . We use 4-neighbor moves with per-step transition cost

$$\ell(i \rightarrow j) = 1 + \mathbb{I}\{C_j = P_{\text{pen}}\} P_{\text{pen}}, \quad h(n) = |x_n - x_g| + |y_n - y_g| \quad (\text{Manhattan heuristic}),$$

and forbid transitions through blocked cells ($C = 100$). The heuristic h is admissible and consistent, so A* returns an optimal path under ℓ . In practice, we also compute a variant without penalties Π_k^{nop} and pick, for each segment, the path with the lower total cost; the final route is $\Gamma = \Pi_1 \oplus \dots \oplus \Pi_N$. For execution, we resample Γ every δ meters to produce a concise waypoint list and follow it under velocity saturation in the robot frame.




Fig.1.9: Figure4

Summary of BRI

In summary, our base relocation strategy adopts a two-track structure: (i) when a path is known, we perform autonomous optimization based on the IRM score and movement cost; (ii) when a path is unknown, we combine user-specified routes with cost-map-based refinement. This design satisfies both robot autonomy and user-driven interaction, achieving flexible and robust base relocation.

1.4.3 Human-Intent Adaptive Grasp Manipulation (HIGM)

Even when the base position is appropriate, discrepancies between human intent and the robot's kinematic constraints can cause the End-Effector (EE) to approach the target in unstable poses. This can lead to grasp failure or excessive joint load. To address this issue, we propose an *adaptive grasp framework* that integrates Pregrasp design, null-space optimization, and a finite state machine (FSM).

Pregrasp and EE interpolation: Human operation alone may command poses that are difficult for the robot to execute. For example, if the user attempts to pinch the top of a bottle, directly mapping the hand-back pose to the EE could result in an unstable grasp configuration.

To address this, as shown in Figure 1.10, we generate a robot-friendly reference pose (Pregrasp pose $\mathbf{x}_{pre}$) based on the target position $\mathbf{p}_t$. The actual EE target is defined by interpolating between the user's palm pose EE_{palm} and the Pregrasp pose EE_{pre} , depending on the distance d to the target:

$$EE_{target}(d) = (1 - \beta(d)) EE_{palm} + \beta(d) EE_{pre}, \quad (1.17)$$

where $\beta(d) \in [0, 1]$ is a distance-dependent interpolation coefficient.

With this scheme, user intent (EE_{palm}) dominates when the target is far away, and as the robot approaches, the weight gradually shifts toward the stable Pregrasp pose (EE_{pre}). In other words, the user's motion is “magnetically guided” toward the object—similar to aim assist in video games—preserving intuitive control while ensuring stable and safe grasping for the robot.

Furthermore, Pregrasp interpolation provides the global reference, while null-space optimization ensures local stability and safety. Thus, interpolation defines “which pose should be aimed for,” and null-space optimization ensures “how to safely approach that pose.” Combining them achieves grasping that respects user intent while adapting to the robot's kinematic limits.




Fig.1.10: Figure10

Joint refinement through null-space optimization: For redundant manipulators, multiple joint configurations can realize the same EE pose. The set of joint motions that do not affect the EE is called the *null space* [19][20].

Formally, the task-space velocity $\dot{x}$ and joint velocity $\dot{\theta}$ satisfy

$$\dot{x} = J\dot{\theta}. \quad (1.18)$$

A velocity $\dot{\theta}_{null}$ belongs to the null space if

$$J\dot{\theta}_{null} = 0. \quad (1.19)$$

Such motions leave the EE unaffected while adjusting only the joint posture.

We exploit this property to simultaneously achieve the primary task and optimize joint posture. The joint velocity is given by

$$\dot{\theta} = J^+ \dot{x}_d + P \nabla_{\theta} H(\theta), \quad (1.20)$$

where the damped least-squares pseudoinverse is

$$J^+ = J^{\top} (J J^{\top} + \lambda I)^{-1}, \quad (1.21)$$

and $P = I - J^+ J$ is the null-space projector. The first term guarantees EE tracking, faithfully reproducing the user's hand motion. The second term optimizes posture in the null space using the merit function $H(\theta)$ (Figure1.10):

$$H(\theta) = w_{mani} \log \det(J J^{\top}) + w_{limit} \sum_i \log m_i(\theta) - \gamma \|\theta - \theta_{pre}\|^2. \quad (1.22)$$

The roles of each term are:

- $w_{mani} \log \det(J J^{\top})$: maximizes Yoshikawa's manipulability[21], avoiding singularities and preventing the arm from losing freedom. This maintains motion redundancy, providing the user with smooth and continuous operation.
- $w_{limit} \sum_i \log m_i(\theta)$: enlarges the margin $m_i(\theta)$ to joint limits[22], preventing joints from approaching boundaries. This ensures mechanical safety and reduces the risk of sudden motion stops, improving user comfort.

- $-\gamma\|\theta - \theta_{pre}\|^2$: maintains consistency with the Pregrasp pose, preventing optimization from drifting too far from user intent. This balances intuitive operation and kinematic stability.

Thus, null-space optimization ensures (1) stability through singularity avoidance, (2) safety through joint-limit avoidance, and (3) intent preservation through Pregrasp consistency. It functions not only as numerical stabilization, but as a foundation linking “robotic physical constraints” with “the user’s continuous intuitive experience.”




Fig.1.11: Figure11

Grasp Readiness Finite State Machine: To ensure that the entire grasping operation proceeds safely and stably, this study introduces a Finite State Machine (FSM) consisting of four states. A Finite State Machine (FSM) is a classical modeling approach that defines system behavior as a combination of states and state transitions [23] [24]. Each state specifies the system’s behavior, and transitions to other states occur in response to external inputs or internal conditions. This simple yet explicit framework makes it possible to manage complex actions step by step, thereby facilitating safety and stability assurance. Through the FSM, both the reflection of user intent and the accommodation of the robot’s kinematic constraints are guaranteed, preventing failures such as the robot “approaching the target in an unstable posture.”

The roles and transitions of the states are:

1. **TRACK:** The robot follows the target using Palm/Pregrasp interpolation. Mathematically, the EE target pose $EE_{target}(d)$ is generated and joint angles are updated via DLS-IK. User experience: “the robot hand smoothly follows my hand.”
2. **BACKOFF:** If manipulability $M(\theta) < \tau_{mani}$ or margin $m_i(\theta) < \tau_{limit}$, the robot retreats to avoid instability. This prevents “robot jamming” and provides the user with a sense of safety.
3. **REALIGN:** After BACKOFF, null-space optimization realigns the joints until $M(\theta) \geq \tau_{mani}$ and $m_i(\theta) \geq \tau_{limit}$. User experience: “the robot autonomously reconfigures itself,” revealing its adaptiveness.

4. **APPROACH:** Once stability is secured and the target distance $d < \tau_{dist}$, the EE approaches to grasp. This corresponds to “the robot decisively grabs,” improving grasp success.

The FSM links mathematical criteria (manipulability, joint margin, distance thresholds) with user experience (tracking feel, safety, adaptiveness, visible grasp action). In particular, the BACKOFF $\rightarrow$ REALIGN transition guarantees that even if the user makes errors, the robot autonomously corrects them, realizing “collaborative safety” in HRC.




Fig.1.12: Figure12

1.4.4 Significance of Module Integration

The proposed HRI-CAS consists of three modules: Target Bottle Inference (TBI), Base Relocation based on IRM (BRI), and Human-Intent Adaptive Grasp Manipulation (HIGM). Each module functions independently, but more importantly, they complement each other to overcome the limitations faced by conventional MR-based HRC systems.

First, TBI accurately estimates the user’s intent, clarifying “which object should be manipulated.” This object information is then passed to BRI, which determines whether base relocation is necessary depending on the object’s reachability. Subsequently, HIGM leverages the outputs of TBI and BRI to compensate for discrepancies between human intent and robot kinematic constraints, ensuring stable grasping.

Through the integration of TBI, BRI, and HIGM, the system establishes a coherent workflow: (1) recognizing user intent with high precision, (2) ensuring reachability through appropriate base relocation, and (3) guaranteeing grasp stability. As a result, the robot operates intuitively and adaptively without over-relying on the user’s physicality, providing a stable interaction experience for both novice and expert users.

Thus, the significance of this research lies not merely in individual technical improvements, but in the establishment of an integrated framework for HRC in MR environments,

encompassing the flow of “intent recognition $\rightarrow$ reachability assurance $\rightarrow$ stable grasp.”

1.5 Experiment on BRI

1.5.1 Experimental Setup

We fixed the BRI evaluation to the *known-path* case (navigation available from the occupancy grid and A*). The user-edited route (unknown-path) variant is reported as an ablation in the appendix.

To verify the effectiveness of the proposed base relocation strategy based on the Inverse Reachability Map (BRI), a stepwise pick-and-place experiment was designed. The experiments were conducted using the KUKA YouBot platform, which integrates omni-directional base mobility with a 5-DOF manipulator. Plastic bottles were used as target objects, and they were deliberately placed at positions that were unreachable from the robot’s initial base position.

The user was positioned approximately 1.0 m away from the robot and monitored and assisted the task through an MR device.

The experiments were divided into two phases. In **Phase 1**, the robot base was relocated once using the BRI strategy, followed by a single pick-and-place operation of one bottle. The objective of this phase was to confirm whether the robot could move to a position where grasping was physically feasible, in accordance with the optimal solution computed from the IRM score and relocation cost. In **Phase 2**, an additional base relocation was performed, after which the robot was tasked with sequentially executing pick-and-place operations for two bottles. This phase aimed to examine whether BRI could maintain task stability through multiple relocations. Each task was repeated 10 times for each participant.




Fig.1.13: Overview of BRI pipeline

The evaluation metrics were as follows: (i) grasp success rate, defined as the percentage of trials in which the target object was correctly picked up and placed at the designated

position; (ii) accuracy of the relocation decision, i.e., whether the base positions computed by BRI corresponded to physically feasible grasping positions; and (iii) time required for base relocation as well as the overall task completion time.

We define the “optimal-base hit rate” as the proportion of trials in which the final executed base pose $\mathbf{b}^*$ yields at least one feasible IK solution at the task point:

$$\text{Hit} \Leftrightarrow N_{\text{IK}}(\mathbf{p}_t \mid \mathbf{b}^*) > 0$$

OccupancyGrid values were mapped to the cost map with obstacle= 100, unknown= 30, free= 0, and a safety dilation penalty $P_{\text{pen}} = 50$. Robot radius for obstacle expansion was fixed to 0.4 m. Waypoint resampling interval was 0.5 m. Path search used 4-neighbor A* with Manhattan heuristic and per-step cost 1 (free) or $1+P_{\text{pen}}$ (penalized cells). When both penalized and non-penalized routes existed, the lower-cost path was selected. All parameters were fixed across participants.

Through this experimental design, the aim was to demonstrate that BRI can autonomously and efficiently relocate the robot base to enhance both grasp success rate and task stability, not only for single-object manipulation but also for tasks involving multiple objects.

1.5.2 Experimental Results

1.6 Experiment on HIGM

1.6.1 Experimental Setup

To clarify the advantages of the proposed Human-Intent Adaptive Grasp Manipulation (HIGM), we conducted a comparative evaluation against the existing MR-based manipulation framework, Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO) [14]. The conventional system places emphasis on directly transferring user operations in MR space to the robot side, without sufficiently considering kinematic feasibility or grasp stability.






Fig.1.14: Sequential pick-and-place before/after

The experimental setup was designed to evaluate both the baseline performance of IRT-MRO and the improvements introduced by HIGHM. Figure ?? illustrates an example of a pick-and-place experiment using the proposed system. Using the KUKA YouBot platform, the user was positioned 1.0 m away from the robot, and the robot was assigned the task of placing two bottles, located within its graspable range, into a designated box. The task was considered successful if both bottles were correctly placed inside the box. In this study, it was assumed that the user was able to perceive the task environment.

As shown in Figures 1.15 a and b, when the user grasped the MR object, the robot simultaneously grasped the corresponding real object. Similarly, when the user released the MR object, the robot released the real object as well (Figures 1.16c and d). Through this sequence of procedures, the pick-and-place task was executed.



(a) before



(b) after

Fig.1.15: Sequential pick-and-place



(a) before

(b) after

Fig.1.16: Sequential pick-and-place

The evaluation was conducted in terms of task execution time measured from initiation to completion, workload assessed using the NASA-TLX, the degree of convergence toward the pregrasp posture (adhesion), the frequency of singularities and joint-limit violations, and the number of regrasp attempts. We fixed all thresholds and weights as follows.

$$\beta(d) = \text{hyst-sigmoid}(d; d_{\text{in}}=0.18 \text{ m}, d_{\text{out}}=0.22 \text{ m}, k=40, \alpha=0.2),$$

DLS damping $\lambda = 10^{-2}$ (adaptive around $e + 0.002$ in implementation), FSM thresholds τ_{mani} (min. singular value) = 0.03, τ_{cond} (condition number) = 60, τ_{limit} (min. joint margin) = 0.08 rad. Backoff distance 0.07 m, REALIGN timeout 0.6 s, and null-space step $k_{\text{null}} = 0.02$. The merit weights are $w_{\text{mani}} = 1.0$, $w_{\text{limit}} = 0.3$, and a weak pull to pregrasp. These values are held constant across participants and trials.

Under these conditions, a comparative experiment was carried out to verify the performance of both systems.

1.6.2 Experimental Results

1.7 Conclusions

第2章 和訳

2.1 序論 (Introduction)

近年、Human-Robot Collaboration (HRC) は製造、物流、医療、災害対応といった多様な現場で実用化が進みつつあり、人間とロボットが協調してタスクを遂行するための重要な研究領域として注目されている [1][2]。特に、従来の完全自律型ロボットでは対処が困難であった非定型作業や予測不能な環境変化に対して、人間の柔軟な判断力とロボットの物理的実行能力を組み合わせることで、作業効率、安全性、適応性を同時に向上させることが可能となる。

HRC における主要な課題の一つは、人間の意図とロボットの認識のずれであり、この齟齬は作業効率の低下や操作の困難さを引き起こす。特に、人間とロボットの身体性の差異に起因する操作ずれは、協調作業における根本的なボトルネックとなっている。この課題に対し、Mixed Reality (MR) を用いて人間の操作をロボットに直感的にマッピングし、ユーザがロボットの動作を自らの身体拡張として認知できるようにするアプローチが注目されている [3][4][5][6][7]。

また、HRC における直感的操作支援の枠組みは、MR に限らず AR や VR に基づいた研究としても多く報告されている。例えば、VR を用いた模倣学習や動作データ収集により、ロボット操作スキルを効率的に獲得させる手法が提案されている一方 [8] [9][10]、AR を用いてロボットの状態や作業手順を提示し、作業者の理解を支援する試みもなされている [11] [12][13]。これらの研究は、人間とロボットの認識のギャップを埋める有効性を示しているが、現実環境とのインタラクションや操作の没入感の点で依然として制約がある。VR は高い没入感と精密な動作記録が可能である一方、現実環境との整合性に欠ける。AR は現実空間に重畳した情報提示によって理解支援を提供するが、操作の直感性は限定的である。この文脈において、現実世界と仮想情報を統合可能な MR は、これらの利点を統合し、現実環境と仮想オブジェクトを同時に扱えるため、HRC の直感的かつ柔軟な操作支援を実現する技術として特に注目されている。

代表的な先行研究として、Esaki らによる Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO) が挙げられる [14]。IRT-MRO は、人間が MR 空間内で仮想オブジェクトを操作し、その操作をロボットが認識する HRI システムである。これは MR を用いた HRC の有効性を示したが、IRT-MRO は「仮想オブジェクトが邪魔でタスク環境が見えにくい場合がある」、「ベース移動に自律性がなく到達範囲外の対象操作が不正確である」、「把持姿勢がロボット側の身体性が考慮されない」、といった課題を残している。

本研究では、これらの課題を克服するために、Human-Robot Interaction with Correction and Suggestion (HRI-CAS) を提案する。本システムは、ユーザーの操作特徴量に基づく操作対象推定 (Target Bottle Inference, TBI)、Inverse Reachability Map (IRM) を利用したベース移動戦略 (Base Relocation based on Inverse Reachability Map, BRI)、さ

らに人間とロボットの身体性の違いを補正する把持操作フレームワーク (Human-Intent Adaptive Grasp Manipulation, HIGM) を統合することで構成される。これにより、ユーザーの熟練度に依存しない安定した協調作業を実現し、MR 空間を介した双方向のかつインタラクティブな HRC を目指す。

本研究の貢献 (Contributions)

本研究の主な貢献は以下の 3 点にまとめられる。

- **操作対象推定モジュール (TBI) の提案** ユーザーの操作特徴量 (手先近接度、接触度、視線、腕振り) を統合し、到達可能性に応じた重み付けにより操作対象を推定することで、不要な情報提示を抑えつつ直感的な対象選択を支援した。
- **IRM に基づくベース移動戦略 (BRI) の実現** Inverse Reachability Map を利用して把持可能位置を算出し、MR 空間上で経路を可視化・編集可能とすることで、移動の必要性を判定しつつ自律性とインタラクティブ性を両立させた。
- **人間とロボットの身体性を調和させる把持操作補正フレームワーク (HIGM) の実現** Pregrasp 生成、ヌル空間最適化、有限状態機械 (Finite State Machine, FSM) を組み合わせ、ユーザー操作とロボットの可操作性を常に調和させることで、相互補正と提案に基づくシームレスな協調操作を実現した。

本システムは、ユーザーの操作意図を尊重しつつ、ロボットが適切な補正・提案を行うことで、熟練度に依存しない安定した作業遂行を可能にする。

さらに、本研究で提案する HRI-CAS の枠組みは、製造現場や遠隔保守、医療支援といった人間とロボットが密接に協調する実環境タスクにおける応用可能性を示すものであり、今後の HRC 研究の発展に寄与することが期待される。

2.2 関連研究 (Related Work)

ロボットは、医療、製造、宇宙探査、農業などの幅広い分野において人間の生活や活動を支援する存在として期待されている。しかし、人間とロボットが同一空間で協調的に作業するためには多くの課題が残されている。その一つは、意図や行動に関する相互理解の不足である。人間はロボットの能力や行動を正確に予測しにくく、ロボットも人間の高次目標を十分に解釈できないため、「実行の溝」と「評価の溝」が生じ、円滑な協調を阻害している。従来のインターフェースはジョイスティックやキーボードを介した操作が主流であったが、2D ディスプレイ上での視覚化は奥行き情報に乏しく、操作者の空間認識や臨場感を制限していた。

こうした課題に対して、Mixed Reality (MR) を活用した Human-Robot Collaboration (HRC) の研究は近年大きく進展している。MR を利用してロボットの稼働状況や環境情報を重畳表示することで、ユーザーは直感的な操作を行うことが可能となり、遠隔操作や協調作業における効率向上が期待されている [3][4][5][6][7]。加えて、AR や VR を応用した研究も広く展開されており、VR では模倣学習や動作データ収集を通じてロボットのスキル獲得を支援し [8] [9]、AR では作業手順やロボット状態の提示によって作業者の理解を

補助する取り組みが行われている [11] [12]。しかし、現実環境とのインタラクションや操作没入感の点で依然として制約があり、現実世界と仮想情報を統合可能な MR は、HRC のための有力な基盤技術として特に注目されている。

これまでの MR ベースの HRC 研究は大きく二つの方向に分類できる。

第一に、**ロボット状態の可視化** を目的とする研究群である。センサデータやロボットの内部状態を MR 空間に投影し、ユーザーの状況認識や意思決定を支援するアプローチが提案されている [15]。この方向性は、環境理解の強化や操作者の認知負荷軽減に寄与する一方で、ロボットの動作計画や操作への直接的な介入は限定的である。

第二に、**ユーザー操作の直感的マッピング** に焦点を当てる研究群である。ハンドトラッキングやジェスチャ入力をロボット動作に変換することで、操作性や没入感を高める試みがなされている [3][4][5][6][7]。このアプローチは操作者の意図をより自然に反映できるが、操作の安定性やロボット側の可操作性保証が十分でない場合が多い。

この分野の代表的研究として、Esaki らによる *Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO)* がある [14]。IRT-MRO は、(i) ロボット視点の情報提示を行う可視化システム、(ii) マーカーおよび点群に基づくキャリブレーション機構、(iii) ハンドトラッキングに基づくマニピュレーションシステム、(iv) ユーザー例示動作を利用したベース移動システムを統合した枠組みである。ボトルを対象としたピック&プレース課題において、70～80 % という一定の成功率を達成していることが示された。これにより、MR を用いた直感的操作支援と経路編集の有効性が実証された。

しかし、IRT-MRO を含む既存研究には依然として課題が残されている。第一に、関節軌道における衝突回避機構が未導入であり、把持動作の失敗を引き起こす可能性がある。第二に、MR デバイスの演算性能や視覚的制約に強く依存するため、システム全体の操作性や適用範囲が制約される。第三に、実験結果からも示されるように、タスク成功率や作業速度が操作者の熟練度に大きく依存している。さらに、多数対象を扱う場合には、MR 空間上に過剰なオブジェクトが表示され、環境の視認性が低下する問題も報告されている。

総じて、既存研究は MR を用いた HRC の有効性を明確に示してきた一方で、環境情報の統合不足、冗長自由度を考慮した安定操作の欠如、ベース移動戦略の自律性の不足といった課題を解決できていない。また、ハプティクスの欠如やリアルタイム処理性能の制約といった MR 技術自体の限界も残されている [16]。このような背景の下で、本研究では **Human-Robot Interaction with Correction and Suggestion (HRI-CAS)** を提案する。

2.3 Human-Robot Interaction with Correction and Suggestion (HRI-CAS)

Human-Robot Interaction with Correction and Suggestion (HRI-CAS) は従来の MR ベースの HRC システムが抱える、環境情報の活用不足、安定した姿勢保証の欠如、ベース移動戦略の自律性不足といった制約を克服する。

本システムは *Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO)* をもとに構成されており、IRT-MRO に存在していた課題を改善している形になっている。IRT-MRO では Hololens2 を用いた Unity ベースのホログラフィックアプリケーションを活用していたが、本システムでは、MetaQuest を用いた Unity ベー

スのパススルーアプリケーションを活用する。両者はいずれも現実世界のオブジェクトを MR 空間に反映できるデバイスであるが、表示方式に大きな違いがある。Hololens2 は光学シースルー方式を採用しており、ユーザは透過ディスプレイ越しに現実環境と仮想オブジェクトを同時に視認できる。一方で、視野角の狭さや表示輝度の制約が指摘されている。これに対して 図 1 に示すように、Meta Quest はパススルー方式を採用し、外部カメラで取得した映像をディスプレイに投影することで、広い視野角と高解像度の表示を実現する。これにより、ユーザはより自然で没入感のある MR 体験を得られ、環境理解や操作の直感性が向上する。




Fig.2.1: Figure1

2.3.1 実装プラットフォームとシステム

本研究においては KUKA YouBot を実験プラットフォームとして採用した。当該ロボットは全方向移動を可能とする台車に加え、5 自由度のマニピュレータおよび二指グリップを搭載したモバイルマニピュレータである。本システムでは、MR 空間上で検出される対象オブジェクトの位置および姿勢の変化、ユーザー操作をロボット動作へと反映させることで、人間とロボットとの間に円滑な相互作用を実現する。さらに、ロボットの挙動は MR 空間へ即時にフィードバックされ、操作者に対して高精度な視覚的情報提示を行う。

グラフィカルアーキテクチャは図 2 に示され、以下の 3 つのモジュールで構成されている。




Fig.2.2: Figure2

Target Bottle Inference (TBI) モジュール: ユーザの視線，頭部方向，および手先運動を MR 空間内で追跡し，候補ボトルとの幾何学的関係の特徴量として抽出する。これらの情報は統合スコアに基づいて処理され，ユーザが操作対象として意図しているボトルを推定する。本モジュールは，ユーザ行動の多様な特徴を統合的に評価することで，高精度かつリアルタイムな対象選択を可能にする。

Base Relocation based on Inverse Reachability Map (BRI) モジュール: 対象ボトルがロボットの可動範囲外に存在する場合に作動する。まず Reachability Map (RM) を基に Inverse Reachability Map (IRM) を生成し [17]，対象位置を到達可能とする候補ベース位置集合を抽出する。次に，IRM スコアおよび移動コストを考慮した最適化問題を解き，最適なベース配置を決定する。さらに，候補経路は MR 空間上に可視化され，ユーザによる修正操作も可能となる。

Human-Intent Adaptive Grasp Manipulation (HIGM) モジュール: ユーザの操作とロボットの身体的制約の差異を補正することを目的とする。具体的には，ユーザのハンドトラッキング情報から得られる参照姿勢と，ロボットにとって把持可能性の高いプレグラスポースを統合し，ヌル空間最適化を利用して関節姿勢を調整する。これにより，ユーザはロボットの運動学的制約を意識することなく，自然な操作感覚で安定した把持を実現できる。

これらのモジュールの統合により，従来の IRT-MRO では十分に対応できなかったユーザの操作対象に応じた動作選択が可能となり，より直感的かつ適応的な経路計画が実現される。さらに，ユーザがロボット固有の身体的制約を意識することなく操作できるようになった結果，適応的な把持動作が可能となり，操作習熟度への依存度が大幅に低減された。これにより，経験の浅いユーザにおいても円滑かつ安定した操作が実現される。

2.3.2 MR システム実装

Unity および MRTK3 (Mixed Reality Toolkit) を基盤とし, OpenXR 標準に準拠して実装された。ユーザは手指運動を介して MR オブジェクトを操作することが可能であり, 直感的かつ自然な入力インタフェースを提供する。さらに, MR オブジェクトを通じてロボットの行動意図を提示することにより, 操作者はロボットの意思決定過程を理解しやすくなり, 人間とロボットの協調性が向上する。

2.4 Module of Human–Robot Interaction with Correction and Suggestion (HRI-CAS)

2.4.1 操作対象推定モジュール (Target Bottle Inference, TBI)

特徴量の定義: TBI モジュールは, ユーザの身体運動に基づいて操作対象を推定することを目的とする。図 3 は情報空間にある操作特徴量の様子である




Fig.2.3: Figure3

対象オブジェクト o_i の位置を $\mathbf{p}_i(t)$ とし, ユーザの眼・頭・手の位置をそれぞれ $\mathbf{p}_{eye}(t)$, $\mathbf{p}_{head}(t)$, $\mathbf{p}_{hand}(t)$ とする。各オブジェクトに対して, ユーザ身体部位からの相対位置方向を示す正規化ベクトルは次式で表される:

$$\mathbf{d}_i^{eye}(t) = \frac{\mathbf{p}_i(t) - \mathbf{p}_{eye}(t)}{\|\mathbf{p}_i(t) - \mathbf{p}_{eye}(t)\|}, \quad \mathbf{d}_i^{head}(t) = \frac{\mathbf{p}_i(t) - \mathbf{p}_{head}(t)}{\|\mathbf{p}_i(t) - \mathbf{p}_{head}(t)\|}, \quad \mathbf{d}_i^{hand}(t) = \frac{\mathbf{p}_i(t) - \mathbf{p}_{hand}(t)}{\|\mathbf{p}_i(t) - \mathbf{p}_{hand}(t)\|}. \quad (2.1)$$

これらは「ユーザがどの方向に注視／注力しているか」を幾何的に定義する基礎ベクトルである。また, 動作のダイナミクスを取り入れるために, 視線ベクトル, 頭部方向ベクトル, および手先加速度ベクトルをそれぞれ正規化し, $\hat{\mathbf{v}}_{gaze}(t)$, $\hat{\mathbf{v}}_{head}(t)$, $\hat{\mathbf{a}}_{hand}(t)$ と定義する。

コサイン類似度スコア: ユーザの身体運動と対象オブジェクトの方向が一致するかどうかを評価するため, 各特徴量と方向ベクトルの内積に基づくコサイン類似度を計算する。

$$s_{gaze}(i, t) = \max(0, \hat{\mathbf{v}}_{gaze}(t) \cdot \mathbf{d}_i^{eye}(t)), \quad (2.2)$$

$$s_{head}(i, t) = \max(0, \hat{\mathbf{v}}_{head}(t) \cdot \mathbf{d}_i^{head}(t)), \quad (2.3)$$

$$s_{accel}(i, t) = \max(0, \hat{\mathbf{a}}_{hand}(t) \cdot \mathbf{d}_i^{hand}(t)). \quad (2.4)$$

ここで s_{gaze} は「視線が各対象に向いている度合い」, s_{head} は「頭部の指向が各対象を捉えている度合い」, s_{accel} は「手先の加速度が各対象方向に向いている度合い」を表す。

さらに, 物理的接触可能性を表す指標として, 手先位置とのユークリッド距離に基づく近接スコア s_{prox} , および実際の接触有無を示すバイナリ変数 $c_i(t)$ を導入する:

$$s_{\text{prox}}(i, t) = \text{clip} \left(1 - \frac{\|\mathbf{p}_{\text{hand}}(t) - \mathbf{p}_i(t)\|}{R_{\text{max}}}, 0, 1 \right), \quad c_i(t) \in \{0, 1\}. \quad (2.5)$$

これにより, 身体運動だけでなく「物理的把持可能性」も同時に考慮する。ここで $c_i(t)$ は最終決定における強制的なフラグとして用い, 特徴ベクトルには含めない。

スコア統合: 以上の特徴量をまとめた特徴ベクトルを

$$\mathbf{s}(i, t) = [s_{\text{prox}}, s_{\text{gaze}}, s_{\text{head}}, s_{\text{accel}}]^\top \quad (2.6)$$

とし, 対象が到達可能集合 $\mathcal{B}_{\text{in}}(t)$ に属するか, 到達不可能集合 $\mathcal{B}_{\text{out}}(t)$ に属するかによって, 別々の重み付けで統合スコアを算出する:

$$S(i, t) = \begin{cases} \mathbf{w}_{\text{in}}^\top \mathbf{s}(i, t), & i \in \mathcal{B}_{\text{in}}(t), \\ \mathbf{w}_{\text{out}}^\top \mathbf{s}(i, t), & i \in \mathcal{B}_{\text{out}}(t). \end{cases} \quad (2.7)$$

ここで $\mathbf{w}_{\text{in}}, \mathbf{w}_{\text{out}}$ は事前に設定された重みベクトルである。到達可能な対象に対しては「近接度」や「手先の動き」を重視することで, ノイズ的な視線の揺れに惑わされず堅牢に推定できる。一方, 到達不可能な対象に対しては「視線」や「頭の向き」を重視することで, ユーザの遠隔意図を正しく反映する。これにより, 状況に応じた柔軟かつ誤検出耐性の高い推定が可能となる。

時間平滑化: 瞬間的な身体動作の揺らぎによりスコアが急激に変動することが予想されるため, 指数移動平均を導入してスコアを時間的に平滑化する [18]。

$$\bar{S}(i, t) = \alpha S(i, t) + (1 - \alpha) \bar{S}(i, t - 1), \quad \alpha \in (0, 1]. \quad (2.8)$$

ここで $\bar{S}(i, t)$ は平滑化総合スコア, α は平滑化係数を示す。これにより, 一時的な誤検出を抑制し, ユーザ意図を安定的に捉えることが可能となる。

最終決定ルール: 最終的な操作対象は, まず「接触有無」を優先基準として決定される。すなわち,

$$i^*(t) \in \{i \in \mathcal{B} \mid c_i(t) = 1\}. \quad (2.9)$$

すなわち, どの候補に対しても接触フラグが立った場合, その対象が即座に最終決定対象となる。

それ以外は全候補集合 $\mathcal{B}$ に対して平滑化スコアを最大化する対象として選択される:

$$i^*(t) = \arg \max_{i \in \mathcal{B}} \bar{S}(i, t). \quad (2.10)$$

ただし, 選択対象は以下の閾値条件を満たす必要がある:

$$\bar{S}(i^*(t), t) \geq \begin{cases} T_{\text{in}}, & i^*(t) \in \mathcal{B}_{\text{in}}(t), \\ T_{\text{out}}, & i^*(t) \in \mathcal{B}_{\text{out}}(t). \end{cases} \quad (2.11)$$

ここで T_{in}, T_{out} はそれぞれ到達可能集合・到達不可能集合に対する判定閾値を表す。この二段階判定により、スコア最大の対象が必ずしも採用されるわけではなく、「操作対象として十分に意図が強い場合のみ」確定する仕組みとなっている。

情報提示の調整: TBI モジュールでは、推定結果をユーザに提示する際に、過剰な情報提示を避けつつ直感的な理解を促すために情報量の調整を行う。

まず、図 4 に示すように各対象ボトルが *Reachability Map (RM)* [17] において「把持可能」か「把持不可能」かを判定し、把持可能な対象はベースカラーで表示する。一方、把持不可能な対象は半透明化し、彩度を低下させることでユーザの注意を必要以上に引かないようにする。




Fig.2.4: Figure4

さらに、図 5 に示すように対象推定によって操作対象が決定された場合には、推定対象以外を一括して半透明表示に切り替える。その際、把持可能対象と把持不可能対象とで UI 強調の方法を区別し、前者には「操作可能性の高さ」を示す強調色を、後者には「ベース移動が必要である」ことを示す異なる色調を割り当てる。




Fig.2.5: Figure4

この二段階の情報量調整により、ユーザは「ロボットが現時点で把持可能な対象」と「移動を必要とする対象」とを明確に区別できる。また、最終推定対象を強調することで選択操作の誤りを抑制し、認知負荷を軽減しながら直感的な意思決定を支援する。

TBI まとめ 以上のように、TBI モジュールはユーザの視線・頭部方向・手先運動など多様な身体特徴量を幾何学的に定義し、コサイン類似度や近接・接触指標に基づいて統合

スコアを算出することで、操作対象を高精度かつリアルタイムに推定する仕組みを構築している。また、時間平滑化により一時的な誤検出を抑制し、安定した対象推定を保証している。

さらに、推定結果は MR 空間において視覚的に提示される。具体的には、Reachability Map (RM) に基づく「把持可能／不可能」の判定に応じて、対象が把持可能であればベースカラーで表示し、不可能であれば半透明化や彩度低下によって情報量を削減する。また、操作対象として推定されたボトルは強調表示され、把持可能対象と不可能対象で異なる強調色を用いることで、ユーザに対して明確なフィードバックを提供する。

このように、TBI モジュールは「対象推定」と「情報提示」を統合的に扱うことで、ユーザの認知負荷を軽減しつつ操作対象の誤選択を防止する。結果として、HRI-CAS 全体の基盤となる「人間の意図の正確な把握」を実現している。

2.4.2 逆到達可能マップに基づくベース移動 (Base Relocation based on Inverse Reachability Map, BRI)

対象がロボットの可動範囲外にある場合には、ロボットベースそのものを移動させる必要がある。しかし、無秩序に移動候補を探索すると計算コストが膨大となり、また人間との協調を考慮した適切な配置を得ることが困難となる。本研究では、2.6 に示すロボットマニピュレータ研究で広く利用される到達可能マップ (*Reachability Map*, *RM*) と逆到達可能マップ (*Inverse Reachability Map*, *IRM*) の概念を導入し、候補ベース位置を生成・評価する [17]。



(a) ReachabilityMap

(b) InverseReachabilityMap

Fig.2.6: RM/IRM

到達可能性と逆到達可能性の基礎: ロボットのベース位置を $\mathbf{b}$ としたとき、その位置からエンドエフェクタ (EE) が到達可能な空間は

$$RM(\mathbf{b}) = \{\mathbf{p} \in \mathbb{R}^3 \mid \exists \theta \text{ s.t. } FK(\theta, \mathbf{b}) = \mathbf{p}\}, \quad (2.12)$$

で定義される。ここで $FK(\theta, \mathbf{b})$ は順運動学を表し、関節角 θ が存在すれば点 $\mathbf{p}$ に到達できることを意味する。すなわち RM は「ある固定ベース位置から、アームがどこまで手を伸ばせるか」を定義するマップである。

逆に、ある対象点 $\mathbf{p}_t$ に対してそれを到達可能とするベース位置集合は

$$\mathcal{B}(\mathbf{p}_t) = \{\mathbf{b} \in \mathbb{R}^3 \mid \mathbf{p}_t \in RM(\mathbf{b})\}, \quad (2.13)$$

と定義され、この集合を 逆到達可能マップ (*IRM*) と呼ぶ。すなわち *IRM* は「タスク点に到達できるベース位置の集合」を与える逆写像であり、ベース移動を考慮する上で不可欠な概念である [17]。

さらに *RM* は単なる到達可能／不可能の判定だけでなく、「その位置に対して逆運動学解が何通り存在するか」を用いて到達の安定性や冗長性を評価できる。本研究では、位置 $\mathbf{p}$ に対して存在する逆運動学解の数を次式によりスコア化する：

$$S_{RM}(\mathbf{p}) = N_{IK}(\mathbf{p}). \quad (2.14)$$

解が多いほど、関節の自由度を活かした柔軟な動作が可能となるため、把持成功率が高まる。

IRM は *RM* の逆写像であるため、対象位置 $\mathbf{p}_t$ に対して得られる候補ベース位置 $\mathbf{b} \in \mathcal{B}(\mathbf{p}_t)$ には、対応する *RM* スコアがそのまま割り当てられる：

$$S_{IRM}(\mathbf{b}; \mathbf{p}_t) = N_{IK}(\mathbf{p}_t | \mathbf{b}). \quad (2.15)$$

これにより、候補ベース配置の良否を、単に「到達できるか否か」ではなく、「どれだけ冗長で安定した姿勢で到達できるか」に基づいて評価できる。

次に、候補集合 $\mathcal{B}(\mathbf{p}_t)$ の中から最適なベース位置を選択する。ここでは、2.7 のような環境情報の有無に応じて二つの場合に分けて定式化する。




Fig.2.7: Figure7

経路既知の場合

目標位置までの移動経路が既知（ナビゲーション可能）である場合、*IRM* スコア $S_{IRM}(\mathbf{b}; \mathbf{p}_t)$ と移動コスト $C(\mathbf{b})$ の両者を考慮し、

$$\mathbf{b}^* = \arg \max_{\mathbf{b} \in \mathcal{B}(\mathbf{p}_t)} [S_{IRM}(\mathbf{b}; \mathbf{p}_t) - \lambda C(\mathbf{b})]. \quad (2.16)$$

ここで $C(\mathbf{b})$ はナビゲーションで得られた $\mathbf{b}_0 \rightarrow \mathbf{b}$ の経路長とする：

$$C(\mathbf{b}) = L(\Gamma(\mathbf{b})) = \int_0^1 \|\dot{\mathbf{x}}(s)\| ds \approx \sum_{k=1}^N \|\mathbf{x}_k - \mathbf{x}_{k-1}\|.$$

得られた候補ベース位置や経路（Waypoint 列）は MR 空間に提示され、ユーザは Waypoint を操作して経路修正できる。

ユーザインタラクション（経路編集の数理反映） MR 空間でユーザが編集した参照経路を $\bar{\Gamma}_u = \{\bar{\mathbf{x}}_k\}_{k=0}^N$ 、ピン留め集合を $\mathcal{K}_{\text{lock}}$ とする。各候補ベース $\mathbf{b}$ に対し、ナビゲーションは

$$C(\mathbf{b} \mid \bar{\Gamma}_u) = C(\mathbf{b}) + w_{\text{trk}}^{\text{nav}} \sum_{k \notin \mathcal{K}_{\text{lock}}} \|\mathbf{x}_k - \bar{\mathbf{x}}_k\|^2, \quad \text{s.t. } \Gamma(\mathbf{b}) \in \mathcal{F}_{\text{nav}}, \quad \mathbf{x}_k = \bar{\mathbf{x}}_k \quad (k \in \mathcal{K}_{\text{lock}})$$

を最小化する経路 $\Gamma(\mathbf{b})$ を再計算し、その結果で (2.16) を再評価する。最終的なベースは

$$\mathbf{b}^* = \arg \max_{\mathbf{b} \in \mathcal{B}(\mathbf{p}_t) \cap \mathcal{F}_{\text{nav}}} \left[S_{\text{IRM}}(\mathbf{b}; \mathbf{p}_t) - \lambda C(\mathbf{b} \mid \bar{\Gamma}_u) - \xi \Delta\psi(\mathbf{b})^2 \right]$$

として選択され、更新後の Waypoint 列 $\Gamma(\mathbf{b}^*)$ は即時に MR 空間へ再描画される。




Fig.2.8: Figure4

経路未知の場合

一方、環境情報が不完全で経路生成が不可能な場合には、先行研究 IRT-MRO [14] の方式に基づき、ユーザが MR 空間上でベース配置経路を直接提示する。本研究ではさらに、提示された経路に対してコストマップを用いた局所的な自律修正を加える。これにより、図 9 に示すように、各 Waypoint は安全かつ実行可能な位置に調整され、障害物回避や環境変化に適応できる。修正結果は MR 空間にも反映されるため、ユーザはロボットによる自律補正を視覚的に理解できる。




Fig.2.9: Figure4

コストマップ (OccupancyGrid → 安全余裕付きグリッド) : 占有格子 $G \in \{-1, 0, 100\}^{H \times W}$ (未知 = -1, 自由 = 0, 障害物 = 100) からコストマップ $C \in \mathbb{R}^{H \times W}$ を構成する。まずセル毎の基礎コスト

$$C_{ij} = \begin{cases} 100 & (G_{ij} = 100) \text{ [通行不可]} \\ P_{\text{unk}} & (G_{ij} = -1) \text{ [未知セルの弱ペナルティ]} \\ 0 & (G_{ij} = 0) \end{cases}$$

を与え、次に障害物近傍へマンハッタン距離 d_1 による膨張 ($d_1 \leq d_{\text{avoid}}$) を行い $C_{ij} \leftarrow P_{\text{pen}}$ とする (形態学的膨張; 安全マージン付与)。さらにロボット半径 r_{safe} と地図解像度 h からセル半径 $r_c = \lceil r_{\text{safe}}/h \rceil$ を求め、ユークリッド距離 $\leq r_c$ の円盤近傍でも $C_{ij} \leftarrow P_{\text{pen}}$ としてミンコフスキー和に基づく実機幅の膨張を付加する。ここで $P_{\text{pen}} \gg 1$ は「通れるが高コスト」を意味し、障害物から離れた経路を自然に選好させる (図 2.9 参照)。:contentReference[oaicite:0]index=0

経路提案 (MR 参照 → 安全 A* 補正) : MR 空間でユーザが提示した参照経路 $\bar{\Gamma} = \{\bar{\mathbf{x}}_k\}_{k=0}^N$ を逐次的な **経由点** とみなし、各区間 ($\bar{\mathbf{x}}_{k-1} \rightarrow \bar{\mathbf{x}}_k$) について膨張コストマップ上で A* 探索を実行して安全経路 Π_k を得る。A* の 1 ステップ移動コストは

$$\ell(i \rightarrow j) = 1 + \mathbb{I}\{C_j = P_{\text{pen}}\} P_{\text{pen}}, \quad h(n) = |x_n - x_g| + |y_n - y_g| \text{ (マンハッタン)},$$

とし、通行不可セル ($C = 100$) は遷移禁止とする。このとき h は許容的かつ一貫的であり、A* は ℓ に対して最適経路を返す。実装では、(a) ペナルティを有効にした経路 Π_k^{pen} と (b) ペナルティを無効化した経路 Π_k^{nop} を両方計算し、合計コストが小さい方を区間経路として採択、 $\Gamma = \Pi_1 \oplus \dots \oplus \Pi_N$ を構成する。さらに実行上は一定間隔 δ 毎にサンプリングして Waypoint 列に圧縮し、機体座標への変換と速度飽和の下で逐次追従する (現在姿勢は $\text{map} \rightarrow \text{base_link}$ の TF から取得)。:contentReference[oaicite:1]index=1

BRI まとめ

以上により、本研究のベース移動戦略は、(i) 経路が既知の場合には「IRM スコアと移動コストに基づく自律最適化」、(ii) 経路が未知の場合には「ユーザ提示とコストマップ補正の組合せ」を適用する二段階構造となっている。これにより、ロボットの自律性とユーザ主導のインタラクションの両方を満たすことが可能となり、柔軟かつ堅牢なベース移動を実現する。

2.4.3 人間意図適応型把持操作補正 (Human-Intent Adaptive Grasp Manipulation, HIGM)

ベース位置が適切であっても、人間の操作意図とロボットの運動学的制約が一致しない場合、エンドエフェクタ (EE) が不安定な姿勢で対象に接近し、結果として把持失敗や関節への過負荷が発生する可能性がある。この問題を克服するために、本研究では Pregrasp 設計、ヌル空間最適化、および有限状態機械 (FSM) を統合した適応型把持フレームワークを提案する。

Pregrasp と EE 補間: 人間の操作情報のみでは、ロボットにとって把持が困難な姿勢が指示される場合がある。例えば、ユーザがボトル上部をつまむように操作した場合、その手の甲位置を目標として EE を制御すると、把持可能性を考慮しない不適切な姿勢が指示される可能性がある。

この問題に対処するため、本研究では図 10 のように対象位置 $\mathbf{p}_t$ に基づき、ロボットにとって安定かつ実行可能な参照姿勢（プレグラスプ姿勢 $\mathbf{x}_{pre}$ ）を生成する。実際の EE 目標姿勢は、ユーザのパーム姿勢 EE_{palm} とプレグラスプ姿勢 EE_{pre} を距離依存で補間することで定義される：

$$EE_{target}(d) = (1 - \beta(d)) EE_{palm} + \beta(d) EE_{pre}, \quad (2.17)$$

ここで $\beta(d) \in [0, 1]$ は対象までの距離 d に基づく補間係数である。

この仕組みにより、対象が遠い段階ではユーザ意図 (EE_{palm}) を強く反映し、対象に接近するにつれてロボットにとって安定なプレグラスプ姿勢 (EE_{pre}) へと比重を移す。言い換えれば、ユーザ操作は「吸着的に」対象へと補正され、ゲームにおけるエイムアシストのように、自然な操作感を維持しつつ、最終的にロボットにとって安全かつ安定した把持が保証される。

さらに、本研究ではこの Pregrasp 補間を大域的な指標として用い、局所的にはヌル空間最適化によって姿勢を補正する。すなわち、Pregrasp 補間が「どの姿勢を目指すべきか」を与え、ヌル空間最適化が「その姿勢に至る過程で安全性や操作性をどう確保するか」を保証する。両者を組み合わせることで、ユーザ意図を尊重しながら、ロボットの運動学的制約に適応した安定的な把持動作が実現される。




Fig.2.10: Figure10

ヌル空間最適化による関節洗練: ロボットアームなど冗長マニピュレータでは、同じ EE (エンドエフェクタ) 位置・姿勢を実現できる複数の関節解が存在する。このとき、EE の運動に影響を与えない自由度の集合を *ヌル空間 (Nullspace)* と呼ぶ [19][20]。

数学的には、タスク空間速度 $\dot{x}$ と関節速度 $\dot{\theta}$ を結ぶ関係式

$$\dot{x} = J\dot{\theta} \quad (2.18)$$

に対して

$$J\dot{\theta}_{null} = 0 \quad (2.19)$$

を満たす $\dot{\theta}_{null}$ がヌル空間に属する。すなわち、これらの運動は EE の位置や姿勢に影響を与えず、関節姿勢のみを調整できる自由度を表す。

この性質を利用し、本研究ではタスク達成と並行して関節姿勢の最適化を行う。関節速度は次式で与えられる：

$$\dot{\theta} = J^+ \dot{x}_d + P \nabla_{\theta} H(\theta), \quad (2.20)$$

ここで J^+ はダンピング付き最小二乗擬似逆行列

$$J^+ = J^{\top} (J J^{\top} + \lambda I)^{-1}, \quad (2.21)$$

$P = I - J^+ J$ はヌル空間射影行列である。第一項は EE の追従を保証し、ユーザが指示した手先運動を忠実に再現する。一方、第二項はヌル空間に射影された最適化成分であり、図 10 に示すようにメリット関数 $H(\theta)$ に基づいて関節姿勢を調整する。

メリット関数は次式で定義される：

$$H(\theta) = w_{mani} \log \det(J J^{\top}) + w_{limit} \sum_i \log m_i(\theta) - \gamma \|\theta - \theta_{pre}\|^2. \quad (2.22)$$

各項の役割は以下の通りである：

- $w_{mani} \log \det(J J^{\top})$ ：吉川可操作度 [21] を最大化することで、ヤコビアンの特異点近傍を回避し、アームが「動きにくい方向」に陥らないよう制御する。物理的には、関節の自由度を活かして運動の冗長性を維持することを意味し、ユーザにとっては操作が途切れず滑らかに続く感覚を保証する。

- $w_{limit} \sum_i \log m_i(\theta)$: 各関節のリミット余裕 $m_i(\theta)$ [22] を増大させることで、関節角が可動範囲の端に近づくことを防ぐ。これはロボットの寿命や安全性を確保する上で重要であり、同時にユーザにとって「無理な姿勢で動作が急に止まる」といった違和感を減少させる。
- $-\gamma \|\theta - \theta_{pre}\|^2$: Pregrasp 姿勢との整合性を維持しつつ、ロボットが独自の最適化によりユーザ意図から大きく逸脱するのを防ぐ。この項によって、ユーザの操作感覚とロボットの運動学的安定性の間にバランスが保たれる。

以上により、ヌル空間最適化は (1) 特異点回避による操作の安定性, (2) 関節リミット回避による機構的安全性, (3) Pregrasp 整合性によるユーザ意図の保持を同時に満たす枠組みとなる。すなわち、単なる数値的安定化にとどまらず、「ロボットの物理的制約への適応」と「ユーザが感じる直感的で継続的な操作体験」とを結びつける基盤技術として機能する。




Fig.2.11: Figure10

把持準備のための有限状態機械: 把持動作全体を安全かつ安定的に進行させるために、本研究では 4 状態からなる有限状態機械 (FSM) を導入する。有限状態機械 (Finite State Machine; FSM) とは、システムの挙動を「状態 (state)」と「状態遷移 (transition)」の組み合わせとして定義する古典的なモデリング手法である [23] [24]。各状態はシステムの振る舞いを規定し、外部入力や内部条件に応じて別の状態へと遷移する。この単純かつ明確な枠組みによって、複雑な動作を段階的に管理でき、安全性や安定性を保証しやすくなる。

FSM によって、ユーザ意図の反映とロボットの運動学的制約の両立を保証し、「無理な姿勢で対象に突入する」といった失敗を防ぐ。

各状態の役割と遷移条件は以下の通りである。

1. **TRACK:** Palm/Pregrasp ブレンドに基づいて対象を追従する段階である。数値的には EE の目標姿勢 $EE_{target}(d)$ を生成し、DLS-IK により関節角を逐次更新する。ユーザ体験的には「手を動かすとロボットも同調して追従する」感覚が得られる。
2. **BACKOFF:** 可操作度 $M(\theta) < \tau_{mani}$ または関節リミット余裕 $m_i(\theta) < \tau_{limit}$ に達した場合、不安定姿勢に突入するリスクが高まるため一旦後退する。この制御は「ロボットが無理に動こうとして詰まる」感覚を防ぎ、ユーザに安心感を与える。
3. **REALIGN:** BACKOFF の後、ヌル空間最適化を用いて関節姿勢を再整列させる。条件 $M(\theta) \geq \tau_{mani}$ かつ $m_i(\theta) \geq \tau_{limit}$ を満たすまで調整が行われる。この段階で

は「ロボットが自律的に姿勢を整える」挙動が見え、ユーザはロボットの適応性を直感的に理解できる。

4. **APPROACH**: EE が安定姿勢を満たし、対象までの距離 $d < \tau_{dist}$ となった場合に接近する。この状態は「ロボットが確実に掴みに行く」段階に相当し、把持成功率の向上に直結する。

以上のように、FSM は数理的基準（可操作度、関節余裕、距離閾値）とユーザ体験（追従感、安心感、適応性、可視的な把持動作）を結びつける仕組みである。特に BACKOFF → REALIGN の遷移は、ユーザが誤った操作を行ってもロボット側が自律的に補正することを保証し、HRC における「協調的な安全性」を実現する。




Fig.2.12: Figure10

2.4.4 モジュール統合の意義

本研究で提案する HRI-CAS は、操作対象推定 (TBI)、ベース移動計画 (BRI)、および把持操作補正 (HIGM) の三つのモジュールから構成される。各モジュールは独立して機能するだけでなく、相互に補完しあうことで、従来の MR ベース HRC システムが抱えていた制約を克服する。

まず、TBI はユーザの意図を高精度に推定することで、「どの対象を操作すべきか」を明確化する。この対象情報は BRI に入力され、対象が把持可能か否かに応じて、ロボットベースの移動が必要かどうかを判断する。さらに、HIGM は TBI と BRI の結果を受けて、人間の操作意図とロボットの運動学的制約の差異を補正し、安定した把持を保証する。

このように、TBI・BRI・HIGM の統合により、(1) ユーザの操作意図を正確に認識し、(2) ロボットベースの適切な再配置を通じて到達可能性を確保し、(3) 把持動作の安定性を担保する、という一連の処理フローが成立する。結果として、ロボットはユーザの身体性に依存しすぎることなく直感的かつ適応的に動作し、初心者から熟練者まで幅広いユーザに対して安定した操作体験を提供できる。

したがって、本研究の意義は、個別の技術的改良にとどまらず、MR 環境における HRC の「意図認識 → 到達性保証 → 安定把持」の一体的な枠組みを確立した点にある。

2.5 BRI の実験

2.5.1 実験設定

BRI の評価は **既知経路** ケースに固定した（占有グリッドと A* に基づくナビゲーションが利用可能な場合）。ユーザ編集ルートによる未知経路バリエーションは、付録におけるアブレーションとして報告した。

本研究では、提案する Inverse Reachability Map (BRI) に基づくベース移動戦略の有効性を検証するため、段階的なピック・アンド・プレース実験を設計した。実験には KUKA YouBot プラットフォームを用い、台車による全方向移動と 5 自由度マニピュレータを統合的に活用した。対象物としてペットボトルを用い、ロボットの初期位置からは直接把持が不可能な位置に配置した。

ユーザはロボットから約 1.0m 離れた位置に立ち、MR デバイスを介してタスクを監視および補助する。

実験は 2 フェーズに分けて実施した。まず **Phase 1** では、BRI に基づいてベース位置を一度移動させ、その後 1 本のボトルをピック・アンド・プレースするタスクを課した。ここでは、IRM スコアと移動コストを考慮した最適解に従って、実際に把持可能な位置に移動できるかを確認することを目的とした。次に **Phase 2** では、さらに別のベース移動を行った後、2 本のボトルを連続してピック・アンド・プレースするタスクを実施した。このフェーズでは、BRI が複数回の再配置を通じてタスクを継続的に安定化できるかを検証する。このタスクを約 10 回実施する。




Fig.2.13: Figure4




Fig.2.14: Figure4

評価指標としては、(i) 把持成功率（対象を正しく持ち上げ、指定位置に配置できた割合）、(ii) BRI によって計算されたベース位置が「実際に把持可能な位置」に移動できたかどうかの判定精度、(iii) ベース移動に要した時間および総タスク完了時間を測定した。我々は「最適基底の的中率」を次のように定義する：最終的に実行された基底姿勢 $\mathbf{b}^*$ が、タスク点において少なくとも 1 つの可解な IK 解を持つ試行の割合である。

$$\text{Hit} \Leftrightarrow N_{\text{IK}}(\mathbf{p}_t | \mathbf{b}^*) > 0$$

OccupancyGrid の値はコストマップに次のように変換した：障害物 = 100、未知領域 = 30、自由空間 = 0。さらに安全マージンの拡張に対して $P_{\text{pen}} = 50$ を設定した。ロボット半径による障害物膨張は 0.4 m に固定した。ウェイポイントの再サンプリング間隔は 0.5 m とした。経路探索には 4 近傍 A* を用い、マンハッタンヒューリスティックを採用した。ステップあたりのコストは自由セルで 1、ペナルティセルで $1 + P_{\text{pen}}$ とした。ペナルティ付き経路とペナルティなし経路が両方存在する場合は、総コストの小さい方を選択した。これらのパラメータは、すべての被験者において固定された。

以上の設定により、単一対象から複数対象へのタスク拡張において、BRI が自律的かつ効率的にロボットベースを再配置し、把持成功率と安定性を向上させる能力を明らかにすることを目的とした。

2.5.2 実験結果

2.6 HGIM の実験

2.6.1 実験設定

本研究で提案する Human-Intent Adaptive Grasp Manipulation (HIGM) の優位性を明らかにするため、既存の MR ベースのマニピュレーションフレームワークである Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space (IRT-MRO) [14] と比較を行った。従来システムは MR 空間におけるユーザ操作をそのままロボット側に転送することに重点を置いており、運動学的な実現可能性や把持の安定性を十分に考慮していない。




Fig.2.15: Figure4

本実験設定では、IRT-MRO のベースライン性能と HIGM による改善効果の両方を評価可能なよう設計した。図 23 は、提案システムを用いたピック・アンド・プレース実験の一

例を示している。KUKA YouBot プラットフォームを用い、ユーザをロボットから 1.0m 離れた位置に配置し、ロボットが把持可能範囲内に、2 本のボトルを所定の箱の中に配置するタスクを課した。2 本すべてのボトルが正しく箱に配置された場合に、タスクは成功と見なされる。本研究では、ユーザがタスク環境を認識できることを前提としている

図 24a,b に示すように、ユーザが MR オブジェクトを把持すると、ロボットも実際のオブジェクトを把持する。同様に、ユーザが MR オブジェクトを離すと、ロボットも実際のオブジェクトを離す（図 24c,d 参照）。この一連の手順により、ピック・アンド・プレースタスクが遂行される。




Fig.2.16: Figure4

評価指標は、タスク開始から完了までの実行時間、NASA-TLX に基づく作業負荷、プレグラスプ姿勢への収束度（吸着性）、特異点や関節限界侵害の発生頻度、および再把持試行数とした。

本研究では、すべての閾値と重みを以下のように固定した。

$$\beta(d) = \text{hyst-sigmoid}(d; d_{\text{in}}=0.18 \text{ m}, d_{\text{out}}=0.22 \text{ m}, k=40, \alpha=0.2),$$

DLS ダンピングは $\lambda = 10^{-2}$ （実装上は $e + 0.002$ 周辺で適応的に変化）とした。FSM の閾値は、最小特異値 $\tau_{\text{mani}} = 0.03$ 、条件数 $\tau_{\text{cond}} = 60$ 、最小関節余裕 $\tau_{\text{limit}} = 0.08 \text{ rad}$ とした。バックオフ距離は 0.07 m、REALIGN のタイムアウトは 0.6 s、ヌル空間での更新ステップは $k_{\text{null}} = 0.02$ とした。メリット関数の重みは $w_{\text{mani}} = 1.0$, $w_{\text{limit}} = 0.3$ 、さらに Pregrasp への弱い引き戻し項を設定した。これらの値は、すべての被験者および試行において固定された。

以上の条件の下で、両システムの性能を比較実験により検証した。

2.6.2 実験結果

2.7 結論

参考文献

- [1] Ajoudani, A., Zanchettin, A. M., Ivaldi, S., *et al.*, “Progress and prospects of human–robot collaboration,” *Auton. Robot* 42, 957–975, 2018.
- [2] Matheson, E.; Minto, R.; Zampieri, E.G.G.; Faccio, M.; Rosati, G. “Human–Robot Collaboration in Manufacturing Applications: A Review,” *Robotics* 2019, 8, 100. <https://doi.org/10.3390/robotics8040100>.
- [3] Delmerico *et al.*, “Spatial Computing and Intuitive Interaction: Bringing Mixed Reality and Robotics Together,” *IEEE Robotics & Automation Magazine*, 2022.
- [4] Su, Y.-P.; Chen, X.-Q.; Zhou, T.; Pretty, C.; Chase, G. “Mixed-Reality-Enhanced Human–Robot Interaction with an Imitation-Based Mapping Approach for Intuitive Teleoperation of a Robotic Arm-Hand System,” *Appl. Sci.* 2022, 12, 4740. <https://doi.org/10.3390/app12094740>
- [5] Ens, B.; Lanir, J.; Tang, A.; Bateman, S.; Lee, G.; Piumsomboon, T.; Billingham, M. “Revisiting Collaboration through Mixed Reality: The Evolution of Groupware,” *Int. J. Hum. Comput. Stud.* 2019, 131, 81–98.
- [6] Belen, R.A.J.D.; Nguyen, H.; Filonik, D.; del Favero, D.; Bednarz, T. A “Systematic Review of the Current State of Collaborative Mixed Reality Technologies,” 2013–2018. *AIMS Electron. Electr. Eng.* 2019, 3, 181–223.
- [7] P. Milgram and F. Kishino, “A Taxonomy of Mixed Reality Visual Displays,” *IEICE Transactions on Information and Systems*, vol. E77-D, no. 12, pp. 1321–1329, 1994.
- [8] Weiyong Si, Ning Wang, and Chenguang Yang, “A review on manipulation skill acquisition through teleoperation - based learning from demonstration,” *John Wiley & Sons, Inc.*, vol. 3, no. 1,, 2021.
- [9] Leidner, D, Bartels, G, Bejjani, W et al., “Cognition-enabled robotic wiping: Representation, planning, execution, and interpretation,” *Robotics and Autonomous Systems*, no. 114, pp. 199–216, 2019.
- [10] Zhang, T.; McCarthy, Z.; Jowl, O.; Lee, D.; Chen, X.; Goldberg, K.; Abbeel, P. “Deep Imitation Learning for Complex Manipulation Tasks from Virtual Reality Teleoperation,” In *Proceedings of the 2018 IEEE International Conference on Robotics and Automation (ICRA)*, Brisbane, Australia, 21–25 May 2018; pp. 5628–5635.

-
- [11] Fang, H.C., Ong, S.K., & Nee, A.Y.C., "Novel AR-based interface for human-robot interaction and visualization," *Adv. Manuf.* 2, pp. 275–288, 2014.
 - [12] Chengxi Li, Pai Zheng, Yue Yin, Yat Ming Pang, Shengzeng Huo, "An AR-assisted Deep Reinforcement Learning-based approach towards mutual-cognitive safe human-robot interaction," *Robotics and Computer-Integrated Manufacturing*, vol. 80, pp.102471, ISSN 0736-5845, 2023.
 - [13] Sereno, M.; Wang, X.; Besancon, L.; McGuffin, M.J.; Isenberg, T. "Collaborative Work in Augmented Reality: A Survey," *IEEE Trans. Vis. Comput. Graph.* 2020, 72, 2530–2549.
 - [14] Esaki, H.; Sekiyama, K., "Immersive Robot Teleoperation Based on User Gestures in Mixed Reality Space," *Sensors*, 2024, 24, 5073.
 - [15] Roldán, J.J.; Peña-Tapia, E.; Martín-Barrio, A.; Olivares-Méndez, M.A.; Del Cerro, J.; Barrientos, A. "Multi-Robot Interfaces and Operator Situational Awareness: Study of the Impact of Immersion and Prediction," *Sensors* 2017, 17, 1720.
 - [16] Thorwarth D and Low DA (2021) "Technical Challenges of Real-Time Adaptive MR-Guided Radiotherapy," *Front. Oncol.* 11:634507. doi: 10.3389/fonc.2021.634507
 - [17] S. Jauhri, J. Peters and G. Chalvatzaki, "Robot Learning of Mobile Manipulation With Reachability Behavior Priors," in *IEEE Robotics and Automation Letters*, vol. 7, no. 3, pp. 8399-8406, July 2022, doi: 10.1109/LRA.2022.3188109
 - [18] Charles C. Holt, "Forecasting seasonals and trends by exponentially weighted moving averages," *International Journal of Forecasting*, Vol 20, Issue 1, 2004, pp. 5-10, ISSN 0169-2070, <https://doi.org/10.1016/j.ijforecast.2003.09.015>.
 - [19] Kim, S., Yun, S., & Shin, D. (2021). "Numerical Quantification of Controllability in the Null Space for Redundant Manipulators," *Applied Sciences*, 11(13), 6190.
 - [20] Koszulinski, A., Sandoval, J., Essomba, T., Vendeuvre, T., Zeghloul, S., Laribi, M.A. (2022). "Null-Space Compliance with Non-linear Behavior: Application to Spine Surgery Robotic Platform," In: Müller, A., Brandstötter, M. (eds) *Advances in Service and Industrial Robotics*. RAAD 2022. Mechanisms and Machine Science, vol 120. Springer.
 - [21] T. Yoshikawa: *Analysis and Control of Robot Manipulators with Redundancy*, Proc. of 1st International Symposium of Robotics Research, 735/747, Cambridge, MA, MIT Press (1983)
 - [22] I. Iossifidis and G. Schoner, "Dynamical Systems Approach for the Autonomous Avoidance of Obstacles and Joint-limits for an Redundant Robot Arm," 2006 IEEE/RSJ International Conference on Intelligent Robots and Systems, Beijing, China, 2006, pp. 580-585, doi: 10.1109/IROS.2006.282468.

- [23] Foukarakis, M., Leonidis, A., Antona, M., Stephanidis, C. (2014). “Combining Finite State Machine and Decision-Making Tools for Adaptable Robot Behavior,” In: Stephanidis, C., Antona, M. (eds) Universal Access in Human-Computer Interaction. Aging and Assistive Environments. UAHCI 2014. Lecture Notes in Computer Science, vol 8515. Springer.
- [24] H. -W. Park, A. Ramezani and J. W. Grizzle, “A Finite-State Machine for Accommodating Unexpected Large Ground-Height Variations in Bipedal Robot Walking,” in IEEE Transactions on Robotics, vol. 29, no. 2, pp. 331-345, April 2013, doi: 10.1109/TRO.2012.2230992.